

UNIVERSIDADE FEDERAL DE SERGIPE
QUALIDADE DE SOFTWARE

ESPECIFICAÇÃO E AVALIAÇÃO INICIAL DA QUALIDADE
DE UMA APLICAÇÃO DE IA GENERATIVA

CRAWL4AI

Extração web e rastreabilidade para RAG

DISCENTES: BRÍCIO THYERS DE GOIS MACEDO • CARLOS EDUARDO LAURENTINO DOS SANTOS • DANIEL RODRIGO FERREIRA DOS SANTOS • LETÍCIA REZENDE DOS SANTOS • LUCAS CONCEIÇÃO CELESTINO • MARIA RITA MELO DE SOUZA • RIVALDO JOSÉ NASCIMENTO DOS SANTOS

O QUE É O CRAWL4AI?

É um crawler e scraper web de código aberto, orientado a LLMs. A proposta é transformar a web em Markdown limpo e pronto para consumo por modelos, servindo RAG, agentes e pipelines de dados. É um dos projetos de crawler mais populares do GitHub, mantido por unclecode, e é distribuído via PyPI e via imagem Docker com um servidor de API.

RECORTE: EXTRAÇÃO WEB E RASTREABILIDADE



REQUISITOS DE QUALIDADE

01

RASTREABILIDADE

Cada trecho extraído deve manter vínculo com a URL de origem e a data/hora da coleta.

02

PROVENIÊNCIA DE DADOS

O sistema deve registrar hash do conteúdo extraído e timestamp de renderização de cada página coletada.

03

CONFIABILIDADE

Falhas de extração (indisponibilidade, timeout ou bloqueio) devem ser reportadas explicitamente.

04

ROBUSTEZ

Páginas com carregamento dinâmico (JS) devem retornar conteúdo completo ou erro explícito, nunca conteúdo parcial silencioso.

05

PRIVACIDADE

E-mails, tokens de autenticação e credenciais em texto claro presentes no conteúdo coletado não devem ser persistidos sem mascaramento em logs e saídas.

REQUISITOS DE QUALIDADE

06

ADEQUAÇÃO FUNCIONAL

O sistema deve extrair corretamente o conteúdo principal da página (título, texto, links), descartando menus/rodapé/anúncios via filtro de conteúdo

07

DESEMPENHO

O tempo de resposta para crawling e geração de markdown de uma página única não deve exceder um limiar definido (ex.: 10s sem JavaScript pesado).

08

INTERAÇÃO/USABILIDADE

A API/CLI deve fornecer mensagens de erro compreensíveis e configuração documentada, permitindo que um usuário não especialista entenda falhas comuns (bloqueio, timeout, JS não carregado).

09

MANUTENIBILIDADE

Alterações na versão do Crawl4AI, no modelo de LLM usado na extração ou nos filtros de conteúdo devem ser versionadas e testáveis isoladamente, sem exigir reescrita da pipeline

10

FLEXIBILIDADE

O sistema deve permitir alternar entre estratégias de extração (CSS, XPath, Regex, Cosine, LLM) conforme o tipo de página, sem acoplamento rígido a uma única estratégia.

REQUISITOS DE QUALIDADE

11

SUPERVISÃO HUMANA

Extrações de conteúdo ambíguo, conflitante ou enviesado (opinativo) destinadas a alimentar uma base de RAG devem passar por um ponto de checagem/aprovação humana antes de uso irrestrito

12

SEGURANÇA

O crawler deve respeitar o robots.txt do domínio alvo e resistir a instruções maliciosas embutidas no conteúdo das páginas (ex.: tentativas de prompt injection).

13

RASTREABILIDADE

Toda extração estruturada via LLM deve indicar de qual URL e de qual trecho/chunk específico cada campo extraído foi obtido, não apenas a página de origem como um todo.

14

CONFIABILIDADE

O sistema não deve apresentar como fato dados que o LLM não conseguiu fundamentar no conteúdo efetivamente coletado (confabulação/alucinação na extração).

15

SEGURANÇA

Chaves de API de provedores de LLM (ex.: armazenadas em .llm.env) não devem ser expostas em logs, respostas da API ou mensagens de erro

CRAWL4AI NA ÓTICA DA ISO/IEC 25010:2023


01

A NORMA ISO/IEC 25010:2023 fornece um modelo estruturado de características que permitem verificar que grau um software atende a requisitos concretos de qualidade

02

CARACTERÍSTICAS

A norma organiza a qualidade de produto em nove características. Neste trabalho, analisaremos a conformidade em seis das nove características



ADEQUAÇÃO FUNCIONAL, SECURITY E FLEXIBILIDADE

Elaboramos 12 casos de teste para 15 requisitos de qualidade para avaliar a qualidade do projeto.



ADEQUAÇÃO FUNCIONAL

É consistente em relação à completude, mas algumas páginas extraídas ainda incluíram conteúdo indesejado.



SECURITY

Houve uma grave falha de segurança que envolveu exposição de dados sensíveis.



FLEXIBILIDADE

Apresentou excelente flexibilidade ao permitir troca de provedor de LLM e de estratégia de extração apenas via configuração, sem alterar código.




CONCLUSÃO

Os casos de teste confirmam a tese que o crawl4ai geralmente atende bem às características do modelo ISO/IEC 25010:2023, exceto por um grave problema de segurança.


CONFIABILIDADE, CAPACIDADE DE INTERAÇÃO E MANUTENIBILIDA DE

Elaboramos 12 casos de teste para 15 requisitos de qualidade para avaliar a qualidade do projeto.



CONFIABILIDADE

Aprovada nos 4 casos de teste: falhas foram sempre reportadas de forma explícita, hashes se mantiveram consistentes e nenhuma informação foi inventada.




CAPACIDADE DE INTERAÇÃO

Mensagens de erro técnicas, mas adequadas ao público-alvo da ferramenta: desenvolvedores e integradores familiarizados com Python.



MANUTENIBILIDADE

Troca de provedor de LLM feita apenas via arquivo de configuração, com zero arquivos de código alterados.



CONCLUSÃO

O Crawl4AI se mostrou confiável e de fácil manutenção, mas ainda precisa melhorar a clareza das mensagens de erro para usuários não especialistas.

RESULTADOS DOS CASOS DE TESTE

01

CT-01
Extração estruturada /
Rastreabilidade

 **PARCIAL**

Solicitação de extração da linguagem, descrição e trecho-fonte a partir da documentação oficial do Python.

 Resultado
Parcial (1/2)

 Requisito(s)
RQ-01, RQ-13

 Pontuação
1/2

03

CT-03
Fonte conflitante /
Supervisão humana

 **ADEQUADO**

Comparação de duas fontes sobre o mesmo dado (Produto X) com informações conflitantes.

 Resultado
Adequado (2/2)

 Requisito(s)
RQ-11

 Pontuação
2/2

02

CT-02
Falta de informação /
Não alucinação

 **ADEQUADO**

Pergunta sobre o preço da licença comercial do Python utilizando somente o conteúdo da documentação.

 Resultado
Adequado (2/2)</

RESULTADOS DOS CASOS DE TESTE

AVALIAÇÃO INICIAL • CRAWL4AI • QUALIDADE DE SOFTWARE

EDUARDO

CT-05

URLs inválidas / indisponibilidade

Verificação do comportamento do sistema diante de uma URL inexistente ou indisponível.

Resultado

PARCIAL

Pontuação

1/2

CT-06

Conteúdo dinâmico (JavaScript)

Verificação de extração de conteúdo em páginas com carregamento via JavaScript.

Resultado

ADEQUADO

Pontuação

2/2

CT-07

Dados sensíveis

Verificação da exposição de informações sensíveis em saídas não autorizadas.

Resultado

REPROVADO

Pontuação

0/2

CT-08

Conteúdo principal

Extração do conteúdo principal da página, desconsiderando elementos de navegação e ruído.

Resultado

PARCIAL

Pontuação

1/2

1 caso adequado • 2 casos parcialmente adequados • 1 caso reprovado

RESULTADOS DOS CASOS DE TESTE



LETÍCIA
REZENDE

01

CT-09
Determinismo e Integridade de Hash

ADEQUADO

Validação de imutabilidade: coletas repetidas da mesma página inalterada geram hashes idênticos, enquanto alterações no conteúdo disparam hashes divergentes.

RESULTADO
Adequado

CATEGORIA
Proveniência

PONTUAÇÃO
2/2

02

CT-10
Troca de Provedor via Configuração

ADEQUADO

Alternância de provedor LLM via arquivo .env/config sem refatoração do pipeline orquestrador; execução bem-sucedida e diff isolado às configurações.

RESULTADO
Adequado

REQUISITO
RQ-09 (Manut.)

PONTUAÇÃO
2/2

03

CT-11
Estratégias Múltiplas de Extração

ADEQUADO

Processamento desacoplado da documentação oficial via JsonCss e JsonXPath; ambas extraíram 16 capítulos localmente em esquemas JSON íntegros.

RESULTADO
Adequado

CATEGORIA
Flexibilidade

PONTUAÇÃO
2/2

04

CT-12
Sanitização de Credenciais em Logs

ADEQUADO

Injeção de chave inválida em modo DEBUG provocando erro 401; varredura confirmou mascaramento de segredo via RedactKeyFilter sem exposição em claro.

RESULTADO
Adequado

CATEGORIA
Segurança

PONTUAÇÃO
2/2

4 casos adequados | Pontuação: 8/8 (100%)

CONFORMIDADE COM OS REQUISITOS ESTABELECIDOS

OBRIGADO